

基于 RBF 神经网络 PID 参数的自调节及仿真

史磊, 王蔚

(长春工业大学, 吉林 长春 130012)

摘要: 鉴于传统 PID 控制器不能够对参数进行严格整定的问题, 提出了 RBF 神经网络与传统 PID 控制器相结合而进行参数自调节的一种控制算法。该控制算法能够充分使用 RBF 神经网络的自适应、自学习能力来调整系统的控制参数。在仿真软件 MATLAB2010a 上对所提出的控制算法进行了仿真研究, 仿真结果表明, 所提出的基于 RBF 神经网络的 PID 参数自校正控制算法是可行的和有效的, 与传统 PID 控制器相比具有更强的适应性、鲁棒性, 能够达到令人满意的控制效果。仿真结果充分说明了 RBF 神经网络自适应 PID 控制算法在总体上优于传统的 PID 控制算法, 为今后对风力发电并网逆变器的研究提供了理论和实验基础。

关键词: MATLAB2010a; 并网逆变器; PID 控制; RBF 神经网络

中图分类号: TP273

文献标识码: A

DOI: 10.15913/j.cnki.kjycx.2017.16.064

对于传统的 PID 控制器来说, 它的特点是结构比较简单, 应用性和适应性较其他控制均较广, 可是单一的 PID 控制在很多地方不能满足控制要求, 校正好的控制器在一段时间之后就会出现偏差, 满足不了工业控制生产要求, 比如在时变对象和非线性系统领域就不能够满足工业生产要求。此文就在原控制器基础之上提出了将 RBF 神经网络和 PID 控制技术相结合。对于非线性系统来说, 把两者相结合的控制系统不但能克服 PID 控制原有的缺陷, 而且自学习能力和适应性都显著增强, 解决了 PID 参数难以整定的问题, 具有良好的控制效果。

1 传统 PID 控制器

PID 控制之所以在以前的工业控制中能够被广泛应用, 就是因为它的算法简单、鲁棒性好、可靠性高等优点, 是发展最快的控制策略之一^[1-3]。它由重要的 2 部分组成, 即 PID 控制器和被控对象, 而 PID 控制器又由 P (比例)、I (积分) 和 D (微分) 3 个环节组成。图 1 为 PID 控制器结构模型。




图 1 PID 控制器结构模型

PID 控制器的数学描述为:

$$U(t) = K_p [e(t) + \frac{1}{T_i} \int_0^t e(\tau) d\tau + T_d \frac{de(t)}{dt}]. \quad (1)$$

式 (1) 中: K_p 为比例系数; T_i 为积分时间常数; T_d 为微分时间常数。

在 PID 控制中, 最核心的问题就是对 PID 控制器的参数进行整定, 理论计算整定法和工程整定法是对控制器参数进行整定的最重要的方法, 但是无论采用哪一种方法, 都具有一定的局限性。

2 基于 RBF 神经网络的自适应 PID 算法

2.1 RBF 神经网络结构

RBF 神经网络具有 3 层网络结构, 第一层是输入层, 由信号源组成, 第二层由隐含层组成, 第三层是输出层, 它们之间没有环路。隐含层和输出层的神经元被用来进行数学运算, 虽然 RBF 神经网络有许多函数表达方式, 但是因为高斯函数形式容易表达, 即便是多变量输入, 也不会增加太大的难度, 光滑性又好, 每阶导数都存在, 并且基函数解析性比较好, 所以在此文中隐含层激活函数就取高斯函数^[4], 神经元的基函数就取距离函数。图 2 为 RBF 神经网络结构图。




图 2 RBF 神经网络结构图

本文采用高斯函数的神经网络辨识器, 在神经网络结构中, $X = [x_1, x_2, \dots, x_n]^T$ 为网络的输入向量, $T = [h_1, h_2, \dots, h_j, \dots, h_n]^T$ 就设为隐含层节点径向基向量。

h_j 为高斯函数, $h_j = \exp\left[-\frac{\|x - c_j\|^2}{2b_j^2}\right]$, $j = 1, 2, 3, \dots, m$.

隐含层第 j 个节点的中心矢量为: $C_j = [c_{j1}, c_{j2}, c_{j3}, \dots, c_{jn}, \dots, c_{jn}]$, $i = 1, 2, 3, \dots, n$.

隐含层节点基宽向量为: $B = [b_1, b_2, \dots, b_n]^T$, b_j 为隐层节点 j 的基度参数, 且为大于零的数。

网络的权向量为: $w = [w_1, w_2, \dots, w_i, \dots, w_n]^T$.

辨识网络的输出为: $y_m = w_1 h_1 + w_2 h_2 + \dots + w_m h_m$, 设在第 k 时刻辨识系统的理论输出为 $y(k)$, 辨识网络的输出为 $y_m(k)$, 则辨识器的性能指标函数为:

$$E_i = \frac{1}{2} [y(k) - y_m(k)]^2.$$

根据梯度下降法, 中心节点、节点基宽参数以及输出权值的迭代算法如下。

中心节点:

$$\Delta c_{ji} = [(y_{out}(k) - y_m(k)) w_j] \frac{x_j - c_{ji}}{b_j^2}. \quad (2)$$

$$c_{ji}(k) = c_{ji}(k-1) + \eta \Delta c_{ji} + \alpha [c_{ji}(k-1) - c_{ji}(k-2)]. \quad (3)$$

基宽参数:

$$b_j(k) = b_j(k-1) + \eta \Delta b_j + \alpha [b_j(k-1) - b_j(k-2)]. \quad (4)$$

$$\Delta b_j = [y_{out}(k) - y_m(k)] w_j h_j \frac{\|x - c_j\|^2}{b_j^3}. \quad (5)$$

输出权值:

$$w_j(k) = w_j(k-1) + \eta [y_{out}(k) - y_m(k)] h_j + \alpha [w_j(k-1) - w_j(k-2)]. \quad (6)$$

上式中: α 和 η 分别为动量因子和学习速率。

雅克比矩阵(即为对象的输出对控制输入的灵敏度信息)算法为:

$$\begin{aligned} \frac{\partial y_{out}}{\partial u} &= \frac{\partial \sum_{j=1}^m w_j h_j}{\partial u} = \frac{\sum_{j=1}^m w_j \partial e\left(-\frac{\|x - c_j\|^2}{2b_j^2}\right)}{\partial u} \\ &= \frac{\sum_{j=1}^m w_j h_j \frac{c_j - x_1}{2b_j^2} \partial x_1}{\partial u} = \sum_{j=1}^m w_j h_j \frac{c_j - x_1}{2b_j^2}. \end{aligned} \quad (7)$$

式(7)中: x_1 是 $u(k)$; h_j 为高斯函数。

NNC 充分利用 RBF 的预测功能, 以雅克比信息作为 k_p , k_i , k_d 调节的因变量。

2.2 RBF 网络 PID 整定原理

图 3 为 RBF 神经网络整定 PID 参数控制结构图。




图 3 RBF 神经网络整定 PID 参数控制结构图

采用增量式 PID 控制器, 控制误差为: $error(k) = rin(k) - yout(k)$ 。

PID 三相输入为:

$$xc(1) = error(k) - error(k-1);$$

$$xc(2) = error(k);$$

$$xc(3) = error(k) - 2error(k-1) + error(k-2).$$

控制算法为:

$$u_{k_p}(k) = k_p [error(k) - error(k-1)];$$

$$u_{k_i}(k) = k_i error(k);$$

$$u_{k_d}(k) = k_d [error(k) - 2error(k-1) + error(k-2)];$$

$$u(k) = u(k-1) + u_{k_p}(k) + u_{k_i}(k) + u_{k_d}(k).$$

$$神经网络指标为: E(k) = \frac{1}{2} error(k)^2.$$

k_p , k_i , k_d 的调整采用梯度下降法:

$$\Delta k_p = -\eta \frac{\partial E}{\partial k_p} = -\eta \frac{\partial E}{\partial y_{out}} \frac{\partial y_{out}}{\partial u} \frac{\partial u}{\partial k_p} = \eta error(k) \frac{\partial y}{\partial u} xc(1);$$

$$\Delta k_i = -\eta \frac{\partial E}{\partial k_i} = -\eta \frac{\partial E}{\partial y_{out}} \frac{\partial y_{out}}{\partial u} \frac{\partial u}{\partial k_i} = \eta error(k) \frac{\partial y}{\partial u} xc(2);$$

$$\Delta k_d = -\eta \frac{\partial E}{\partial k_d} = -\eta \frac{\partial E}{\partial y_{out}} \frac{\partial y_{out}}{\partial u} \frac{\partial u}{\partial k_d} = \eta error(k) \frac{\partial y}{\partial u} xc(3).$$

上式中: $\frac{\partial y}{\partial u}$ 为被控对象的雅克比信息, 能够用神经网络辨识来得到。

3 仿真

为了验证该算法, 采用基于 RBF 神经网络的 PID 参数自整定控制原理, 设被控对象为:

$$yout(k) = \frac{-0.1yout(k-1) + u(k-1)}{1 + yout(k-1)^2}.$$

RBF 网络的结构选为 3-6-1, 3 个输入选 $[u(k), yout(k), yout(k-1)]$ 。取模拟系统参数 $k_p = 0.03$, $k_i = 0.01$, $k_d = 0.03$, 输入指令信号取 $rin(t) = \sin(2\pi t)$, 学习速率取 0.05, 平

滑因子取 0.1。在 $M=1$ 时为通过 RBF 神经网络进行整定的 PID 控制,其仿真结果如图 4 所示;在 $M=2$ 时为未通过 RBF 神经网络进行整定的 PID 控制,其仿真结果如图 5 所示。




图 4 RBF 神经网络整定 PID 控制正弦曲线




图 5 PID 控制正弦曲线

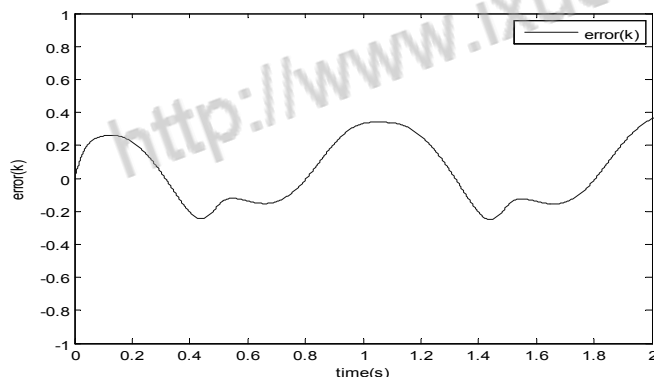


图 6 控制误差

从上图 4 和图 5 的仿真图可以看出,基于 RBF 神经网络的 PID 控制正弦响应曲线使输出近似跟踪输入,并具有一定的抗干扰能力且效果较好,没有经过 RBF 神经网络进行整定的 PID 控制正弦波响应参数相对固定,难以及时遵循动态过程和对象的变化修改参数,同时输出跟踪输入的能力相比于经过神经网络校正后的跟踪能力明显较差,从图 6 控制

误差曲线图中可以看出,控制误差在 $-0.2 \sim 0.4$ 之间波动,相对比较稳定。由此可以看出, RBF 神经网络 PID 控制在跟踪性能上较单一 PID 控制策略而言更优良,具有更强的抗干扰能力。图 7 为参数自适应调节图。




图 7 参数自适应调节

4 结论

RBF 神经网络与传统 PID 控制相结合,充分发挥了 PID 控制的优势,在一定程度上弥补了 PID 控制的不足,解决了控制参数难以整定的问题,在仿真分析中,较理想地实现了 PID 参数自适应。RBF 神经网络与 PID 控制器的结合,没有太复杂的数学模型,并且自学习能力强,响应更快,充分验证了 RBF 神经网络 PID 参数自适应控制的有效性,本控制算法为工业控制提供了有效的理论和实验基础。

参考文献:

- [1] [美] Martin T.Hagan, Howard B.Demuth.神经网络设计 [M].戴葵,译.北京:机械工业出版社,2002: 99-181.
- [2] 孙亮,杨鹏.自动控制原理 [M].北京:北京工业大学出版社,1999: 53-55.
- [3] 胡寿松.自动控制原理 [M].北京:国防工业出版社,1998: 71-103.
- [4] 刘金琨.先进 PID 控制及其 MATLAB 仿真 [M].北京:电子工业出版社,2003: 104-112.

作者简介:史磊(1988—),男,河南驻马店人,长春工业大学 2015 级电气工程研究生,主要从事电力变换技术与新能源开发方向的研究。王蔚(1976—),男,吉林长春人,长春工业大学副教授,主要从事电力变换技术与新能源开发方向的研究。

[编辑:刘晓芳]

欢迎广大读者踊跃投稿,《科技与创新》期刊投稿邮箱: kjycxzss@126.com



知网查重限时 7折 最高可优惠 120元

本科定稿，硕博定稿，查重结果与学校一致

立即检测

免费论文查重: <http://www.paperyy.com>

3亿免费文献下载: <http://www.ixueshu.com>

超值论文自动降重: http://www.paperyy.com/reduce_repetition

PPT免费模版下载: <http://ppt.ixueshu.com>
